

Aprendizaje por refuerzo y técnicas generativas.

Deep Q Network (DQN)

Introducción a los modelos Generativos

Introducción

Tradicionalmente existen dos paradigmas de aprendizaje y distintos tipos de modelos, como son el aprendizaje ***Supervisado*** y ***No Supervisado***

<p align="center" width="100%"> </p>

Introducción

A su vez, existen diferentes modelos o diferentes problemas (paradigmas) que afrontar con los modelos de IA:

- **Discriminativos:** predicen la probabilidad de pertenecer a una clase dado las características de los datos de entrada.
- **Generativos:** buscan modelar cómo se generan los datos observados y pueden generar nuevos datos similares

<p align="center" width="100%"> </p>

Introducción - paradigmas de los modelos generativos

- No solo aprenden a diferenciar, sino que aprenden la estructura de los datos
- Son útiles en aprendizaje no supervisado
- Es más sencillo obtener una idea de qué caracteriza una clase
- Son más costosos computacionalmente

Introducción - paradigmas de los modelos generativos

Ejemplos y evolución de los modelos generativos:

- Naive Bayes (1960~1970)
- Máquinas de Boltzmann (RBM) (1980)
- Modelos de Markov (HMM) (1960~1970)
- Gaussian Mixture Models (GMMs) (1977)
- Autoencoders variacionales (AEs) (2013)
- Generative Adversarial Networks (GANs) (2014)
- Transformers (2017)
- Diffusion Models (2020)

Autoencoders - AEs

¿Qué son los Autoencoders?

Un tipo de red neuronal que puede aprender a comprimir y luego reconstruir datos.

- Un autoencoder es un tipo de red neuronal utilizada en tareas de **aprendizaje no supervisado**.
- Su objetivo es aprender una **representación compacta** de los datos de entrada.
- Consiste en dos partes principales: el ***codificador*** y el ***decodificador***.
- El objetivo principal de un autoencoder es ***minimizar la diferencia*** entre los datos de entrada y los datos reconstruidos por el decodificador.

¿Qué son los Autoencoders?

Son redes neuronales con una arquitectura compuesta de dos componentes que se entrenan al mismo tiempo:

- **Codificador:** Transforma los datos de entrada en una representación de menor dimensión.
- **Decodificador:** Toma esta representación y reconstruye los datos originales.

<p align="center" width="100%"> </p>

Areas de aplicación

Son muy útiles en una amplia variedad de aplicaciones.

- **Reducción de dimensionalidad:** aprender representaciones comprimidas de datos de alta dimensionalidad, lo que permite reducir el número de características necesarias para describir los datos.
- **Eliminación de ruido:** Al entrenar con datos ruidosos y luego reconstruirlos, se pueden obtener versiones limpias y filtradas de los mismos.
- **Detección de anomalías:** modelar la distribución de los datos normales y detectar desviaciones significativas como anomalías. (detección de fraudes, fallas en equipos, etc.)
- **Generación de datos:** Al muestrear del espacio latente, los autoencoders pueden generar nuevas muestras de ***datos similares*** a los ejemplos de entrenamiento.

<hr>

[Ian Goodfellow](#) menciona que son la primera red generativa.

Arquitectura Convolutional Autoencoder

<p align="center" width="100%"> </p>

Imagen obtenida de [Deep Clustering with Convolutional Autoencoders](#)

Entrenamiento Semi-supervisado

El entrenamiento es exactamente igual que cualquier red neuronal, la diferencia radica en qué se utiliza como "**etiquetas**".

- La **función de pérdida** se calcula comparando la salida obtenida (imagen reconstruida) con los datos que se espera obtener (imagen sin ruido, etc)
- La razón principal por la que se considera "**semisupervisado**" es que el proceso de entrenamiento no requiere etiquetas explícitas (gato, perro, etc).

<p align="center" width="100%"> </p> <hr> «Que no os vendan la moto,
es un entrenamiento supervisado », Edgar Talavera.

Variational Autoencoders

Motivación

Los **Autoencoders** tienen un gran problema: no son buenos generadores de datos.

<center>¿Por qué?</center>

Pensemos en un ejemplo sencillo: la reconstrucción de imágenes del dataset MNIST.

<center>¿Cómo pensáis que será el espacio latente?</center>

Motivación

<p align="center" width="100%"> </p>

Motivación

Al **no ser una distribución de datos continua**, tendremos problemas cuando la entrada sea ligeramente distinta a los datos con los que se entrenó el autoencoder:

`<p align="center" width="100%"> </p>`

¿Qué ocurrirá cuando la entrada sean imágenes que generen espacios latentes entre medio de las muestras de entrenamiento?

Motivación

- **Espacios continuos:** En un espacio continuo, los datos pueden tomar un rango infinito de valores dentro de un intervalo determinado.
- **Espacios discretos:** En un espacio discreto, los datos solo pueden tomar un conjunto finito o contablemente infinito de valores distintos.

<p align="center" width="100%"> </p>

Motivación

La mejor situación que buscamos es conseguir:

- Un espacio latente **continuo** y **ordenado**
- En el espacio ordenado permite tener las muestras similares agrupadas
- No se pierde la capacidad de interpolar entre diferentes muestras

<p align="center" width="100%"> </p>

Motivación - ¿Cómo lo conseguimos?

- Solo podemos forzar a la propia red a que ordene el espacio latente
- ¿Cómo?
- Durante el entrenamiento, se minimiza una función de pérdida
- ¿Y...?
- Pues ahí es donde vamos a trabajar, pero entonces ya no usamos un Autoencoder...

<p align="center" width="100%"> </p>

Variational Autoencoders (VAEs)

Son una variante de los autoencoders que buscan la generación de datos sintéticos.

- Combinan redes neuronales con distribuciones de probabilidad.
- Permiten que los datos generados sigan el mismo patrón que los datos de entrada.

Así, la red aprende los parámetros de una distribución de probabilidad.

- Construyen explícitamente un ***espacio latente continuo y ordenado***.
- No una función arbitraria como en las redes neuronales convencionales.

Variational Autoencoders (VAEs)

El espacio latente está definido por **dos vectores** de tamaño n :

<p align="center" width="100%"> </p>

Luego debemos ajustar las funciones de pérdida individualmente de tal manera que:

- Una ***función de pérdida tradicional*** que calcula la diferencia con el objeto generado.
- La ***divergencia KL*** (Kullback-Leibler) entre la distribución latente aprendida y la distribución anterior (prior distribution), que actúa como término de regularización.

KL-divergence

¿Por qué necesitamos las pérdidas de reconstrucción y la divergencia KL?

<p align="center" width="100%"> </p>

KL-divergence

La **funcion *KL-divergence*** mide la diferencia entre dos distribuciones de probabilidad.

<p align="center" width="100%"> </p>

Por ejemplo, en las distribuciones de la figura tenemos dos distribuciones:

- Una distribución normal y conocida $p(x)$.
- Una distribución normal y desconocida $q(x)$.

Es una divergencia, no una distancia, ya que no es simétrica.

KL divergence

La fórmula de la divergencia Kullback-Leibler (KL) entre dos distribuciones de probabilidad (P) y (Q) es:

<center>

$$D_{\text{KL}}(P \parallel Q) = \sum_i p_i \log \left(\frac{p_i}{q_i} \right)$$

</center>

Donde:

- (p_i) es la probabilidad de la categoría (i) en la distribución (P).
- (q_i) es la probabilidad de la categoría (i) en la distribución (Q).

Aplicada en el contexto de Variational Autoencoders (VAEs) es:

<center>

$$D_{\text{KL}}(P(z) \parallel Q(z)) = \frac{1}{2} \sum_{i=1}^K \left(\sigma_i^2 + \mu_i^2 - 1 - \log(\sigma_i^2) \right)$$

</center>

Donde:

- (K) es la dimensionalidad del espacio latente.
- (μ_i) y (σ_i) son la media y la desviación estándar de la distribución ($P(z)$) en la dimensión (i) del

I now call it “self-supervised learning”, because “unsupervised” is both a loaded and confusing term. [...] Self-supervised learning uses way more supervisory signals than supervised learning, and enormously more than reinforcement learning. That’s why calling it “unsupervised” is totally misleading.

Self-Supervised Learning: From NLP to Recent Advances in Deep Learning (2019) [paper]

Bonus: ¿Aprendizaje supervisado o no supervisado?

Tradicionalmente, se han clasificado como ***aprendizaje no supervisado***.

- Después de todo, no trabajan con datos *etiquetados*.
- ¡Pero no puedes optimizar autoencoders sin la retroalimentación de la propia reconstrucción!

En el ***aprendizaje supervisado***, se aprende con retroalimentación de los datos.

- Se espera que, al proporcionar algunos ejemplos, el algoritmo descubra la función que mapea las entradas a las salidas deseadas con el menor error.

Yann LeCun inventó el término ***aprendizaje auto-supervisado*** para hablar sobre estos modelos.

Recursos didácticos

1. [Reducing the dimensionality of data with neural networks.](#)
[science](#), 313(5786):504–507, 2006
2. [Extracting and composing robust features with denoising autoencoders](#), 2008.
3. [Semi-Supervised Recurrent Variational Autoencoder Approach for Visual Diagnosis of Atrial Fibrillation](#)
4. [Variational Autoencoders](#), Radboud University